

# Aplicação de Redes Neurais Recorrentes (LSTM) para a Previsão de Ativos de Renda Variável: Um Estudo de Caso na B3 (2020-2025)

1º Rodrigo M. de A. Silva

Departamento de Ciência da Computação

Centro Federal de Educação Tecnológica de Minas Gerais

Belo Horizonte, Brasil

rodrigopiece27@gmail.com

**Abstract**—O presente trabalho detalha o desenvolvimento de um pipeline computacional para a gerência e análise de dados do mercado de capitais brasileiro. Utilizando a biblioteca yfinance para a extração de dados históricos de todas as ações listadas na B3, o estudo foca no período de janeiro de 2020 a janeiro de 2025. A metodologia empregada inclui a normalização dos preços de fechamento para uma base comum, permitindo a identificação e análise comparativa das 10 ações com maior variação percentual. Adicionalmente, foi gerado um mapa de calor para visualizar a correlação entre estes ativos de alta performance, oferecendo insights sobre o risco e a diversificação de um potencial portfólio. Por fim, foi implementado e avaliado um modelo de rede neural recorrente do tipo Long Short-Term Memory (LSTM) para a predição de séries temporais dos preços desses ativos. O desempenho do modelo foi quantitativamente aferido por meio das métricas RMSE, MAE, R<sup>2</sup> e MAPE, demonstrando a viabilidade da aplicação de técnicas de machine learning para a modelagem preditiva no contexto financeiro. O estudo corrobora a eficácia de um pipeline automatizado para extrair, analisar e modelar dados financeiros complexos obtidos via web.

**Index Terms**—Mercado de Ações, B3, Análise de Séries Temporais, LSTM, Python, Análise de Correlação.

## I. INTRODUÇÃO

Os primeiros registros de mercados financeiros similares aos contemporâneos surgiram no século XVII na Holanda, com a criação da Bolsa de Valores de Amsterdam, onde comerciantes negociavam ações da Companhia das Índias Orientais [4]. Posteriormente, no final do século XIX, nos Estados Unidos, Charles H. Dow criou o Dow Jones Industrial Average (DJIA), aplicando uma média ponderada dos preços das ações de 12 empresas industriais americanas [5], marcando o início do mercado de índices.

A teoria da eficiência de mercado afirma que os preços dos ativos refletem todas as informações disponíveis publicamente [6], tornando improvável obter lucros anormais consistentes baseados apenas em informações públicas [12]. No entanto, existem evidências de que os preços podem ser influenciados por fatores emocionais e comportamentais [13]. Um estudo de [14] investigou os coeficientes de Hurst das séries de preços de ações, indicando que mercados emergentes são menos

eficientes que os desenvolvidos, resultando em oportunidades para investidores obterem retornos consideráveis.

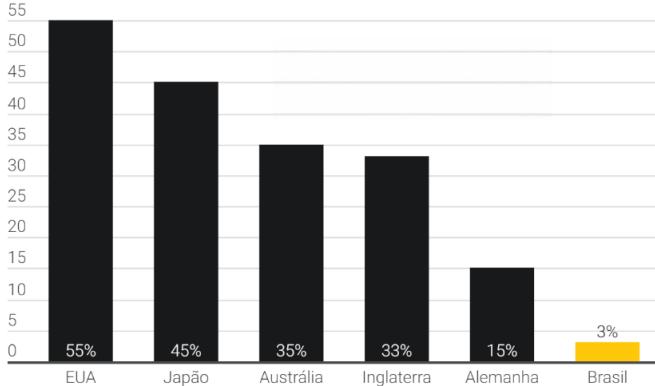
Neste cenário, a busca por estratégias menos arriscadas originou diversos modelos aplicáveis ao mercado financeiro, baseados em Análise Técnica, Análise Fundamentalista, Análise Quantitativa e Análise de Sentimentos. Como consequência, surgiram modelos baseados em Inteligência Artificial (IA) que combinam essas abordagens, permitindo a análise de grandes volumes de dados e o reconhecimento de padrões complexos [15], [16].

[21] mostraram que a previsão de séries temporais pode ser uma ferramenta útil na especulação de retornos de ações. Técnicas de IA podem ser aplicadas a tarefas de previsão de sentido e/ou valor de ativos financeiros devido à sua capacidade de identificar padrões dificilmente observados por humanos [22]. Ainda mais, essas técnicas se justificam dado o recente cenário de períodos de crise, como a pandemia de COVID-19, a volatilidade pós-pandemia [9] e as recentes tensões geopolíticas. Nesses contextos, a eficiência dos mercados financeiros tende a se deteriorar temporariamente, abrindo espaço para padrões mais previsíveis no curto prazo [10]. Estudos mostram que, nesses momentos, os preços apresentam maior autocorrelação, persistência e rupturas na aleatoriedade, o que indica desvios da Hipótese dos Mercados Eficientes [11]. Com isso, os modelos que empregam IA se tornam ferramentas eficazes para explorar ineficiências transitórias e desenvolver estratégias de negociação mais precisas em ambientes marcados por alta instabilidade.

O crescente interesse e participação de pessoas físicas no mercado financeiro têm sido observados globalmente. A globalização dos mercados e o aumento da renda das famílias em países em desenvolvimento são fatores que impulsionam essa tendência [17]. Além disso, a facilidade de acesso à informação e o uso de tecnologias financeiras têm contribuído para o aumento da participação de pessoas físicas na bolsa [18]. Um estudo da XP Investimentos [19] revela que o número de pessoas físicas investindo em ações está diretamente relacionado à estabilidade do mercado e à qualidade de vida nos países analisados. Na bolsa brasileira (B3), houve um aumento de mais de 2,8 milhões de investidores individuais em 2020,

representando um crescimento de 93,7% em relação a 2019 [20].

Fig. 1. Porcentagem de pessoas por país que investem em ações.



Diante desse contexto, torna-se relevante o desenvolvimento de modelos baseados em IA(LSTM) que possam apoiar decisões de investimento. O objetivo geral deste artigo é projetar, implementar e validar um pipeline de ciência de dados ponta a ponta para: (1) extraír e gerenciar dados históricos de todo o universo de ações listadas na B3 no período de 2020 a 2025; (2) realizar uma análise exploratória para identificar os ativos de maior desempenho e visualizar suas correlações; e (3) construir e avaliar um modelo de inteligência artificial baseado em redes LSTM para a previsão de seus preços futuros.

O restante deste artigo está organizado da seguinte forma. A próxima seção (II) apresenta os **materiais e métodos**, a seção III expõe os **resultados** e por fim a seção IV faz as **considerações finais**.

## II. MATERIAS E MÉTODOS

Para atingir os objetivos propostos, este trabalho foi desenvolvido utilizando a linguagem de programação Python e um conjunto de bibliotecas de código aberto especializadas em manipulação de dados, visualização e inteligência artificial. A metodologia é dividida em duas partes principais: a descrição do conjunto de dados utilizado e a apresentação das ferramentas e técnicas empregadas.

### A. Conjunto de Dados

O conjunto de dados para este estudo consiste em séries temporais dos preços históricos de ações negociadas na B3, a bolsa de valores oficial do Brasil. Os dados foram coletados de forma automatizada via web, utilizando a API do Yahoo Finance, que fornece informações financeiras de mercados globais.

As principais características do dataset são:

- **Fonte de Dados:** Yahoo Finance, acessado programaticamente via biblioteca `yfinance`.
- **Universo de Ativos:** O estudo partiu de uma lista de todos os tickers (códigos de negociação) de ações listadas na B3, carregada a partir de um arquivo de referência.

Para cada ticker, foi realizada uma tentativa de download dos dados históricos.

- **Período de Análise:** O foco principal da análise comparativa e da modelagem foi o período entre **janeiro de 2020 e janeiro de 2025**. No entanto, para o treinamento do modelo preditivo, foram baixados dados históricos desde o início de sua disponibilidade (no caso do código de exemplo, a partir de 2007), a fim de fornecer um volume maior de dados para o aprendizado da rede neural.
- **Atributos:** Para cada dia de pregão, os dados coletados incluem o preço de abertura, máxima, mínima, fechamento (Close) e o volume de negociações. O atributo central utilizado tanto para a análise de variação quanto para a modelagem preditiva foi o **preço de fechamento ajustado**, que reflete o valor da ação ao final do dia, já considerando o pagamento de dividendos e outros proventos.

### B. Ferramentas e Técnicas

O pipeline de análise foi construído sobre um ecossistema de ferramentas robustas da linguagem Python:

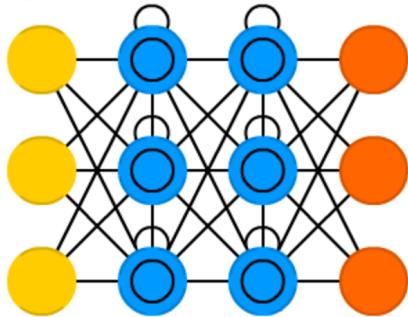
- **Pandas:** Biblioteca fundamental para a manipulação e análise dos dados. Foi utilizada para estruturar as séries temporais em DataFrames, realizar a limpeza, o tratamento de dados ausentes, a normalização dos preços para uma base 100 e para agrregar os resultados.
- **NumPy:** Utilizada para operações numéricas de alta performance, especialmente na preparação dos arrays (matrizes) que servem de entrada para o modelo de deep learning.
- **Matplotlib & Seaborn:** Empregadas para a criação de todas as visualizações do estudo, incluindo os gráficos de linhas para a performance das ações, os gráficos de barras para os rankings e, notadamente, o mapa de calor (heatmap) para a análise de correlação entre os ativos.
- **Scikit-learn:** Utilizada em duas frentes críticas: no pré-processamento dos dados, com a classe `MinMaxScaler` para normalizar os valores antes do treinamento do modelo; e na avaliação do modelo preditivo, com as funções `mean_squared_error`, `mean_absolute_error` e `r2_score`, `mean_absolute_percentage_error` para calcular as métricas de desempenho.
- **TensorFlow e Keras:** Framework de deep learning utilizado para a construção, treinamento e execução do modelo preditivo. Keras, atuando como uma interface de alto nível para o TensorFlow, permitiu a definição da arquitetura da rede neural de forma intuitiva e modular.

### C. Técnica de Previsão: Long Short-Term Memory (LSTM)

Para a tarefa de predição dos preços das ações, foi empregada uma técnica de Inteligência Artificial conhecida como **Long Short-Term Memory (LSTM)**. Uma LSTM é um tipo avançado de Rede Neural Recorrente (RNN), uma arquitetura de deep learning especialmente projetada para aprender com dados sequenciais. [1].

Fig. 2. Arquitetura simplificada de uma rede LSTM.

## Long / Short Term Memory (LSTM)



A figura 2 apresentada por [3] representa de modo simplificado a arquitetura de uma rede LSTM, as celulas azuis são celulas de memorias recorrentes, as amarelas representam as entradas e as vermelhas as saídas.

A escolha da LSTM se justifica por sua capacidade de **capturar dependências de longo prazo** em séries temporais, uma característica essencial para modelar mercados financeiros, onde eventos passados podem influenciar tendências futuras. Ao contrário de modelos estatísticos mais simples, a LSTM consegue aprender padrões complexos e não-lineares diretamente dos dados de preço.

### D. Construção do Algoritmo (Passo a Passo)

O processo de construção do modelo seguiu um pipeline de 6 etapas bem definidas, desde o dado bruto até a previsão final. O modelo em questão foi baseado no modelo LSTM Vanilla de [2].

1) **Coleta e Preparação dos Dados:** Primeiramente, os dados históricos completos de uma ação específica (ex: MNPR3.SA) são baixados da internet usando a biblioteca `yfinance`. O único dado de interesse para a modelagem é a coluna de preços de fechamento (`Close`).

2) **Normalização:** Como redes neurais apresentam melhor convergência com dados em uma escala uniforme, todos os preços de fechamento são transformados para um intervalo entre 0 e 1. Este procedimento é realizado utilizando a função `MinMaxScaler` da biblioteca Scikit-learn.

3) **Criação das Sequências de Treino:** Esta é a etapa crucial para o LSTM. O código “desliza” uma janela sobre a série temporal normalizada. Para cada janela, é gerado um par de dados:

- **Entrada (X):** Uma sequência de 90 dias consecutivos de preços (`look_back = 90`).
- **Saída (y):** O preço do 91º dia.

Este processo é repetido para todo o histórico, gerando um vasto conjunto de exemplos de treinamento para o modelo aprender a relação entre o passado e o futuro.

4) **Divisão em Treino e Teste:** O conjunto de dados estruturado em sequências é dividido em dois subconjuntos: 80% dos dados (os mais antigos) são utilizados para **treinar** o modelo, enquanto os 20% restantes (os mais recentes) são reservados para **testar** a performance do modelo em dados inéditos.

5) **Construção da Arquitetura da Rede Neural:** Utilizando a biblioteca Keras, a arquitetura da rede neural é definida camada por camada de forma sequencial:

- Uma **primeira camada LSTM** com 50 neurônios, responsável por receber as sequências de 90 dias.
- Uma **camada de Dropout** com taxa de 20%, que desativa aleatoriamente alguns neurônios durante o treino para prevenir o sobreajuste (*overfitting*).
- Uma **segunda camada LSTM** com 50 neurônios, para aprender representações mais abstratas dos dados.
- Outra **camada de Dropout** de 20%.
- Uma **camada Densa** de saída, com apenas 1 neurônio, que fornece a predição final do preço.

6) **Treinamento e Previsão:** O modelo é primeiramente **compilado**, definindo o otimizador `adam` e a função de perda `mean_squared_error`. Em seguida, o modelo é efetivamente **treinado** com a função `model.fit`, iterando sobre os dados de treino por múltiplas épocas (`epochs`). A técnica de `EarlyStopping` é empregada para monitorar o processo e interrompê-lo caso o modelo não apresente melhorias, otimizando o tempo de treino. Por fim, o modelo treinado é utilizado para gerar previsões sobre o conjunto de teste, e estes valores são **desnormalizados** para retornarem à escala original de preços em Reais.

## III. RESULTADOS

### A. Maiores 10 variações na B3 (2020-2025)

Para realizar uma análise comparativa justa do desempenho das ações, foi aplicada uma metodologia de normalização de preços. Todos os preços de fechamento dos ativos foram ajustados para uma base comum de 100 no início do período de análise, em janeiro de 2020. Esta técnica permite que o crescimento de cada ação seja visualizado como um índice, facilitando a comparação direta de seu retorno acumulado. Subsequentemente, foi calculada a variação percentual total de cada ativo, desde a data base em janeiro de 2020 até o final do período, em janeiro de 2025, a fim de quantificar o retorno total e identificar os papéis de maior destaque.

Fig. 3. Retorno Acumulado das ações listadas na B3 (2020-2025)

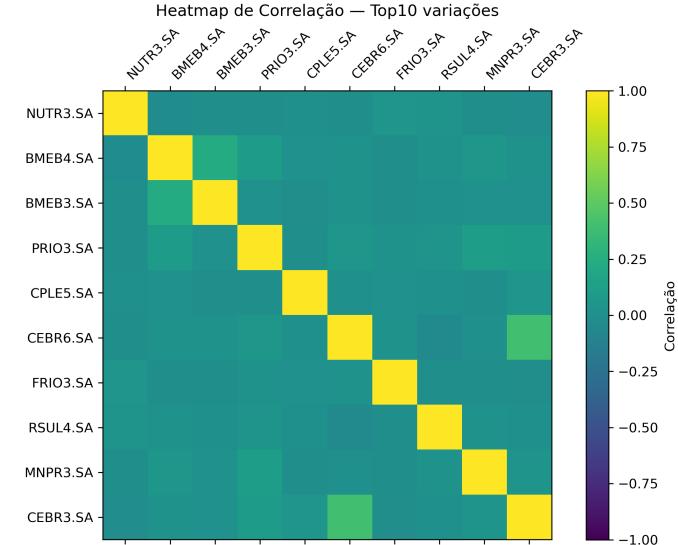


Os resultados desta análise (Fig 3) revelam um crescimento exponencial para um grupo seletivo de ações, com todas as 10 principais apresentando uma valorização superior a 300% no período. O desempenho é liderado por NUTR3.SA e BMEB4.SA, que registraram retornos extraordinários de +757,8% e +705,7%, respectivamente. Outros papéis como BME3.SA (+525,5%), PRIO3.SA (+465,7%) e CPLE5.SA (+451,0%) também se destacam, demonstrando uma performance robusta. É notável a diversidade setorial entre as empresas de melhor desempenho, incluindo companhias dos setores de nutrição, bancário, energia e commodities, o que indica que as oportunidades de crescimento estiveram distribuídas por diferentes áreas da economia brasileira durante o período analisado.

#### B. Correlação de Pearson e Mapa de Calor

A análise de correlação de Pearson (Fig 4), aplicada sobre os retornos diários das 10 ações de maior variação, revela um baixo grau de interdependência linear entre a maioria dos ativos. Os coeficientes, em sua grande parte, situam-se em um intervalo próximo de zero, o que indica que o movimento de preço de uma ação não impacta de forma direta e previsível o das outras. Este achado é particularmente relevante do ponto de vista da gestão de portfólios, pois sugere que uma carteira composta por estes ativos de alta performance seria inherentemente bem diversificada, mitigando o risco não-sistêmico ao evitar que os ativos se movam em bloco.

Fig. 4. Mapa de Calor Correlação B3 (2020-2025)

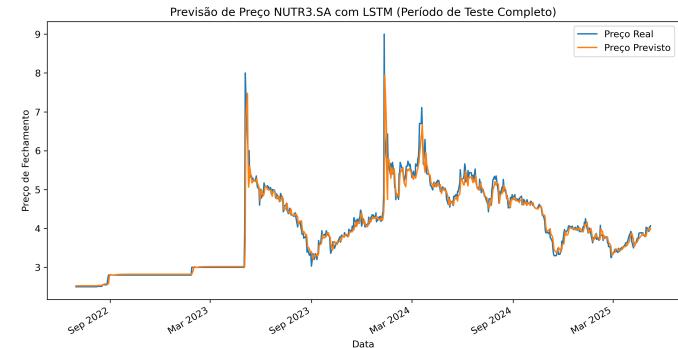


As exceções mais notáveis a essa baixa correlação geral ocorrem, como esperado, entre tickers que representam a mesma companhia. A relação positiva mais significativa foi observada entre CEBR6.SA e CEBR3.SA (+0.39), e a segunda maior entre BMEB4.SA e BMEB3.SA (+0.23). Fora esses casos, as demais correlações, tanto positivas quanto negativas, são muito fracas para terem significância prática. Conclui-se, portanto, que os ativos de maior desempenho no período moveram-se de forma majoritariamente independente, reforçando seu potencial para a composição de uma carteira de investimentos diversificada.

#### C. Previsão do preço das 10 ações com LSTM

A seguir, são detalhados os resultados da modelagem preditiva para as dez ações de maior variação, com foco nos gráficos de desempenho e nas métricas de avaliação do algoritmo LSTM<sup>1</sup>.

Fig. 5. Previsão de Preço NUTR3.SA com LSTM (Período de Teste Completo)

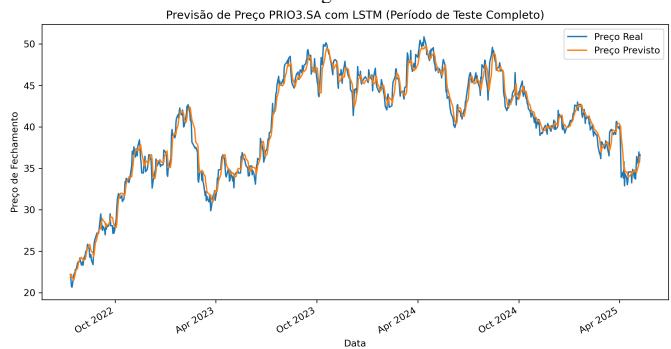


<sup>1</sup>Como o modelo utilizou 80% dos dados históricos para treino e 20% para teste, a data de previsão não coincide necessariamente com o período de janeiro de 2020 a janeiro de 2025

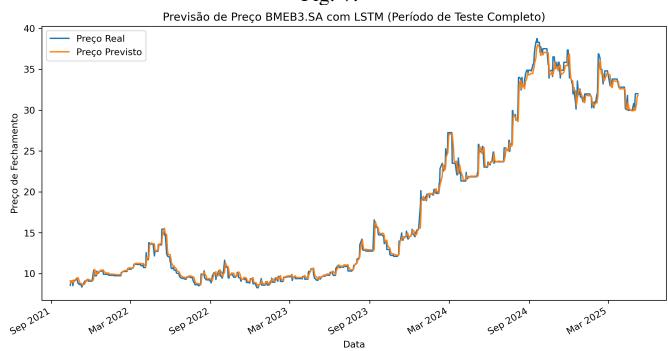
**Fig. 6.**



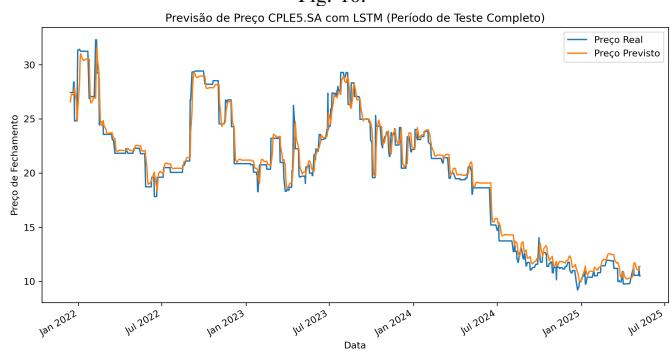
**Fig. 9.**



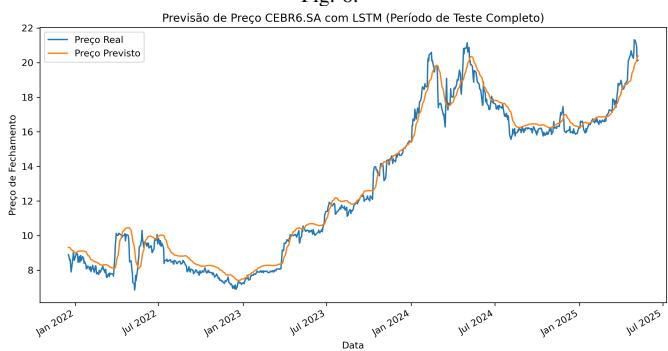
**Fig. 7.**



**Fig. 10.**



**Fig. 8.**



**Fig. 11.**

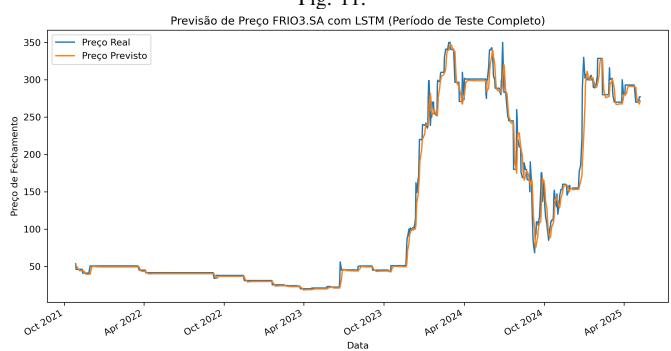


Fig. 12.

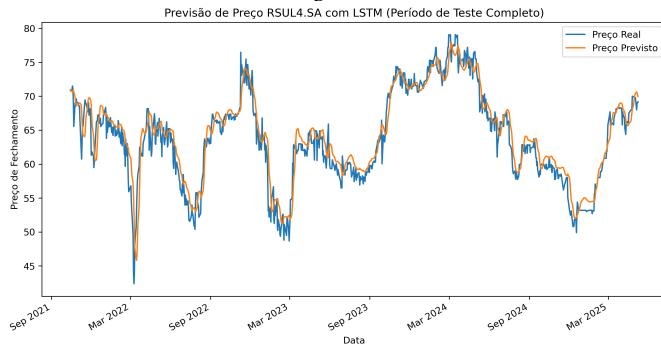


Fig. 13.

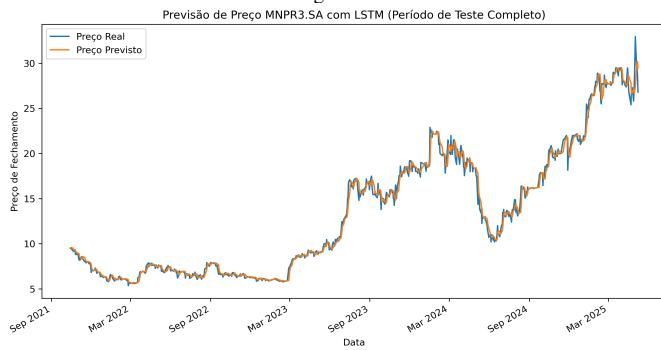
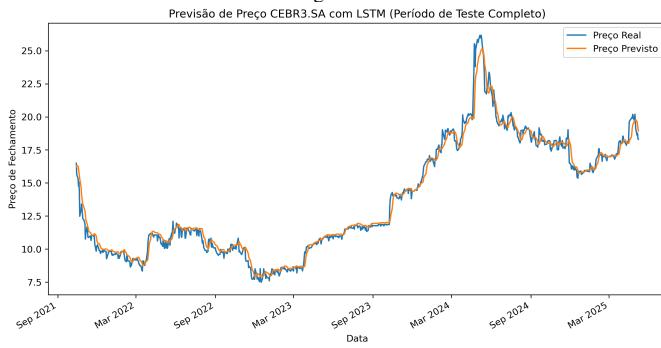


Fig. 14.



As métricas de erro absoluto, MAE e RMSE, são expressas na mesma unidade da variável-alvo (BRL), o que permite uma interpretação financeira direta do desempenho do modelo.

A avaliação quantitativa da performance do modelo LSTM, realizada sobre o conjunto de teste para cada uma das dez ações, corrobora e aprofunda a análise visual. As métricas de desempenho fornecem uma medida objetiva da acurácia e do poder de explicação do modelo. Para uma interpretação clara, é fundamental compreender o significado direto de cada métrica utilizada:

- **Erro Absoluto Médio (MAE):** Expressa em Reais (BRL), esta métrica representa o erro médio absoluto

TABLE I  
MÉTRICAS DE DESEMPENHO DO MODELO LSTM POR AÇÃO

Ticker	MAE (BRL)	RMSE (BRL)	MAPE (%)	R <sup>2</sup>
BMEB3	0,45	0,72	3,04	0,9943
BMEB4	0,71	1,25	3,32	0,9889
CEBR3	0,44	0,66	4,16	0,9805
CEBR6	0,39	0,51	3,78	0,9883
CPLS5	0,64	0,94	3,55	0,9730
FRI03	5,46	12,21	3,75	0,9877
MNPRR	0,41	0,64	3,10	0,9915
NUTR3	0,14	0,35	3,04	0,8821
PRIO3	1,08	1,39	2,78	0,9566
RSUL4	10,08	10,28	30,70	0,7719

da previsão. Ela responde de forma direta à pergunta: “em média, quantos Reais o modelo errou em suas previsões?”.

- **Raiz do Erro Quadrático Médio (RMSE):** Também expressa em BRL, o RMSE quantifica a magnitude típica do erro. Por elevar os erros ao quadrado antes da média, ele penaliza erros grandes de forma mais significativa, sendo um indicador da presença de previsões pontuais muito discrepantes.
- **Erro Percentual Absoluto Médio (MAPE):** Esta métrica contextualiza o erro em termos relativos, respondendo à pergunta: “em média, quantos por cento o modelo errou em relação ao preço real do ativo?”. É particularmente útil para comparar a performance entre ações de diferentes faixas de preço.
- **Coeficiente de Determinação (R<sup>2</sup>):** Diferente das métricas de erro, o R<sup>2</sup> mede o poder de explicação do modelo. Um valor de 0.98, por exemplo, significa que o modelo consegue explicar 98% da variação do preço real, indicando um excelente ajuste à tendência dos dados.

A análise dos resultados consolidados revela um desempenho notavelmente alto para nove das dez ações estudadas. O coeficiente R<sup>2</sup> superou o valor de 0.95 para este grupo, com picos como 0.9943 para BMEB3 e 0.9915 para MNPR3, demonstrando que os modelos foram capazes de acompanhar quase perfeitamente as tendências dos preços. A precisão é reforçada pelo MAPE, que se manteve consistentemente baixo, na faixa de 2.78% a 4.16% para estes mesmos ativos. Em termos monetários, o MAE confirma a robustez do modelo, com erros médios de previsão tão baixos quanto R\$ 0,39 para CEBR6 e R\$ 0,41 para MNPR3.

Entretanto, o caso do ticker RSUL4 destaca-se como uma exceção fundamental. Para este ativo, o modelo apresentou um desempenho significativamente inferior, com um R<sup>2</sup> de apenas 0.7719 e um MAPE elevado de 30.70%. Este resultado discrepante sugere que a série temporal de RSUL4 possui características intrínsecas (como volatilidade mais errática, menor liquidez ou padrões não-lineares mais complexos) que a arquitetura LSTM atual não conseguiu capturar com a mesma eficácia. Este achado é crucial, pois ilustra que, apesar de sua potência, a performance do modelo não é universal e depende das particularidades de cada ativo financeiro, apontando para

a necessidade de otimizações específicas em casos atípicos.

#### IV. CONSIDERAÇÕES FINAIS

Este trabalho detalhou a construção de um pipeline de ciência de dados para analisar e prever o comportamento de ações da B3 entre 2020 e 2025. A metodologia permitiu identificar um seletivo grupo de ativos de alta performance, que se mostraram majoritariamente não correlacionados, e validar um modelo de inteligência artificial (LSTM) para a predição de seus preços. A avaliação quantitativa confirmou a eficácia do modelo para a maioria dos casos, com Coeficientes de Determinação ( $R^2$ ) frequentemente superiores a 0.95 e Erros Percentuais Absolutos Médios (MAPE) abaixo de 5%, atestando a alta precisão e o poder de explicação da abordagem.

Contudo, reconhecem-se as limitações do estudo, evidenciadas pela dificuldade do modelo em prever o comportamento do ativo atípico RSUL4, o que demonstra que a eficácia não é universal e depende das características de cada série temporal. A natureza univariada do modelo, que utiliza apenas o histórico de preços, é a principal limitação. Diante disso, trabalhos futuros podem se beneficiar da inclusão de variáveis exógenas e da otimização de hiperparâmetros para cada ativo, buscando criar modelos preditivos ainda mais robustos e abrangentes para a complexa análise do mercado financeiro.

#### REFERENCES

- [1] Tayib, H.; Abdulazeez, A. (2024). A review of Bitcoin price prediction based on deep learning algorithms. *The Indonesian Journal of Computer Science*, 13(2).
- [2] Brownlee, J. (2018). Deep learning for time series forecasting— Predict the future with MLPs, CNNs and LSTMs in Python. Ebook digital.
- [3] Asimov Institute. (2025). Neural Network Zoo. Disponível em <https://www.asimovinstitute.org/neural-network-zoo/>. Acessado em: 11 de julho de 2025.
- [4] French, D. (2006). The Dutch monetary environment during tulipmania. *The Quarterly Journal of Austrian Economics*, 9(1), 3-14.
- [5] Dow, J. (1986). The Dow Theory. Barron's, 20(28), 1-2.
- [6] Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2), 383-417.
- [7] Mutinda, J. K. e Langat, A. K. (2024). Stock price prediction using combined GARCH-AI models. *Scientific African*, 26, e02374.
- [8] Safari, A. e Ghaemi, S. (2025). NeuroFuzzyMan: A hybrid neuro-fuzzy BiLSTM stacked ensemble model for financial forecasting and analysis: Dataset case studies on JPMorgan, AMZN and TSLA. *Expert Systems with Applications*, 266, 126037.
- [9] Wang, J., Wang X. (2021). COVID-19 and financial market efficiency: Evidence from an entropy-based analysis. *Finance Research Letters*, 42, 101888.
- [10] Izzeldin, M., Muradoglu, Y., Pappas, V., Petropoulou, A., Sheeja S. (2023). The impact of the Russian-Ukrainian war on global financial markets. *International Review of Financial Analysis*, 87, 102598.
- [11] Shahid, M. (2022). COVID-19 and adaptive behavior of returns: evidence from commodity markets. *Humanities and Social Sciences Communications*, 9(1).
- [12] Malkiel, B. G. (2003). The efficient market hypothesis and its critics. *Journal of Economic Perspectives*, 17(1), 59-82.
- [13] Shiller, R. J. (2000). Irrational exuberance. Princeton University Press.
- [14] Cajueiro, D. O., Tabak, B. M. (2004). The Hurst exponent over time: testing the assertion that emerging markets are becoming more efficient. *Physica A: Statistical Mechanics and its Applications*, 336(3-4), 521-537.
- [15] Agrawal, J. G., Chourasia, V. S., Mittra, A. K. (2022). Stock market prediction using machine learning algorithms. *International Journal of Advanced Computer Science and Applications*, 13(1), 1-8.
- [16] Vadlamudi, S. (2017). Stock market prediction using machine learning: A systematic literature review. *American Journal of Trade and Policy*, 4(3), 123-128.
- [17] Kaniel, R., Saar, G., Titman, S. (2008). Individual investor trading and stock returns. *The Journal of Finance*, 63(1), 273-310.
- [18] UNCTAD. (2020). World Investment Report 2020: International Production Beyond the Pandemic. United Nations Conference on Trade and Development.
- [19] XP Investimentos. (2023). Relatório de Investidores Pessoa Física na Bolsa de Valores.
- [20] B3. (2023). Histórico de pessoas físicas na Bolsa de Valores. B3 - Brasil, Bolsa, Balcão.
- [21] Gonzalo, J., Pitarkis, J. Y. (2002). Estimation and model selection based inference in single and multiple threshold models. *Journal of Econometrics*, 110(2), 319-352.
- [22] Korczak, J., Hernes, M. (2017). Deep learning for financial time series forecasting in A-Trader system. In *Proceedings of the 2017 Federated Conference on Computer Science and Information Systems* (pp. 905-912).